



Projet de Data Science

Sujet : Détection d'anomalies



Classification



Anomaly Detection

DIOUF Salimata
KOUAME Christ Ange Dylan
OUATTARA Aboubakar Mohamed
OUATTARA Souleymane

Enseignant : François HU

January 10, 2026

Accès au dépôt GitHub du projet : [Lien d'accès](#)



1 Synthèse de la méthodologie de référence

1.1 Problématique et Objectifs

La détection d'anomalies constitue un enjeu central pour les institutions financières, car la plupart des méthodes classiques reposent sur la modélisation préalable des comportements dits **normaux**, ce qui devient coûteux et peu robuste lorsque les données sont volumineuses et de grande dimension. Cette approche indirecte présente deux limites majeures :

- Inefficacité algorithmique : Les modèles ne sont pas optimisés pour la détection d'anomalies, ce qui entraîne souvent un taux élevé de faux positifs ou une incapacité à détecter les anomalies réelles;
- Contraintes de passage à l'échelle : Ces méthodes sont souvent limitées à des jeux de données de petite taille ou de faible dimensionnalité en raison du coût de calcul élevé des mesures de distance ou de densité;
- Les auteurs proposent de changer d'approche avec une méthode nommée Isolation Forest (iForest). L'objectif est d'exploiter directement les deux caractéristiques fondamentales des anomalies : elles sont rares (minorité) et différentes (valeurs d'attributs extrêmes par rapport à la base de donnée). L'article vise à démontrer qu'en se concentrant sur l'isolation des points plutôt que sur leur profilage, on peut obtenir un algorithme à complexité linéaire, extrêmement rapide et efficace sur de très grands volumes de données.

1.2 Description Formelle de la Méthode

La méthode repose sur l'utilisation d'arbres binaires appelés Isolation Trees. Le principe est simple : si l'on partitionne les données de manière aléatoire, une anomalie sera isolée beaucoup plus rapidement qu'un point normal.

1.2.1 Construction de l'iTree (Phase d'entraînement)

Pour un ensemble de données X' , l'algorithme construit un iTree de manière récursive:

- Il sélectionne aléatoirement un attribut q ;
- Il sélectionne aléatoirement une valeur de coupure p entre le minimum et le maximum de cet attribut;
- Il divise les données : les points où $q < p$ sont envoyés vers le fils gauche, les autres vers le fils droit. Le processus s'arrête lorsqu'une instance est isolée (nœud externe), que toutes les données du nœud sont identiques ou qu'une limite de hauteur est atteinte;

1.2.2 Mesure et Score d'Anomalie

1. Longueur de chemin $h(x)$:
Elle est définie par le nombre d'arêtes parcourues par une instance x de la racine jusqu'à un nœud externe. Plus $h(x)$ est court, plus la probabilité que x soit une anomalie est forte.
2. Score d'anomalie $s(x, \psi)$:
Comme la hauteur des arbres dépend de la taille de l'échantillon (ψ), les auteurs normalisent le résultat pour obtenir un score compris entre 0 et 1. Un score proche de 1 indique une anomalie quasi certaine, tandis qu'un score inférieur à 0,5 indique une instance normale.

1.2.3 Résultats et Conclusions des Auteurs

1.2.3.1 Résultats Expérimentaux

Les principaux résultats mentionnés par les auteurs sont:

- **Supériorité de Performance** : Les tests empiriques montrent qu'iForest surpasse ORCA, LOF et les SVM à une classe en termes de précision (mesurée par l'AUC) et de temps d'exécution . iForest est particulièrement performant sur les jeux de données dépassant les 1000 points.
- **Efficacité Computationnelle** : Grâce à une complexité temporelle linéaire et un besoin mémoire réduit, iForest est capable de traiter un nombre très important d'enregistrements, là où les méthodes basées sur les distances (comme LOF) échouent par manque de ressources.
- **Robustesse** : La méthode gère efficacement les effets de swamping (points normaux identifiés comme anomalies car proches d'elles) et de masking (anomalies dissimulées par leur propre nombre) en utilisant le sous-échantillonnage (subsampling).

1.2.3.2 Conclusions

Les auteurs concluent qu'iForest est la première méthode de détection d'anomalies utilisant l'isolation comme concept fondamental.

Sa simplicité conceptuelle cache une grande efficacité : elle élimine le coût majeur du calcul des distances par paires. Elle est capable de détecter aussi bien des anomalies isolées que des groupes d'anomalies denses, ce qui en fait un outil puissant pour la détection de fraudes d'anomalies.

Haute Dimensionnalité : L'algorithme reste robuste face à un grand nombre d'attributs non pertinents.

2 Protocole expérimental

2.1 Application au Contexte Actuariel

2.1.1 Enjeux et Problématique Métier

Dans le secteur du crédit, l'actuaire doit évaluer avec précision le risque de contrepartie. Les dossiers frauduleux ou incohérents induisent un risque de sous-tarification et des pertes financières directes. L'enjeu de cette étude est double :

- **Sécurisation de l'octroi** : Compléter le scoring traditionnel par une détection précoce des demandes suspectes.
- **Qualité des données** : Identifier les anomalies de déclaration (revenus incohérents, ratios d'endettement extrêmes) pour affiner la tarification.

L'utilisation de variables telles que le `loan_status` et le score CIBIL permet de corrélérer directement les anomalies détectées à un risque de défaut.

2.1.2 Description du Jeu de Données

Le fichier `loan_applications.csv` constitue une base transactionnelle réaliste pour un établissement financier. Les variables sont structurées en quatre familles principales :

- **Caractéristiques du prêt** : Type , montant demandé, durée, taux d'intérêt et but du prêt.
- **Profil socio-économique** : Statut d'emploi, revenu mensuel, âge et charges de famille.
- **Indicateurs de risque de crédit** : Score CIBIL, encours de crédits et ratio dette/revenu.
- **Variables de sortie** : Décision d'approbation et indicateurs de fraude.

2.2 Pertinence d'Isolation Forest pour le Crédit

La base de données présente une forte disproportion entre les demandes standards et les fraudes, ce qui justifie l'utilisation d'iForest pour les raisons suivantes :

1. **Nature des anomalies** : La méthode exploite le fait que les fraudes sont, par définition, rares et différentes des profils d'emprunteurs classiques.
2. **Agnosticisme aux échelles** : Contrairement aux méthodes basées sur les distances (k-NN, SVM), iForest ne nécessite pas de pondération artificielle entre des variables d'unités hétérogènes.
3. **Efficacité opérationnelle** : Sa complexité linéaire permet l'analyse en routine de portefeuilles massifs comprenant des centaines de milliers de dossiers.
4. **Pilotage du risque** : Le score d'anomalie continu permet de prioriser les dossiers nécessitant un contrôle humain renforcé ou d'ajuster dynamiquement les règles d'acceptation.

2.3 Préparation et Ingénierie des Données

Avant l'application des modèles, une phase rigoureuse de préparation des données est nécessaire pour garantir l'intégrité du signal.

2.3.1 Nettoyage du Dataset

- **Gestion des types** : La variable cible `fraud_flag` a été convertie en type booléen. Ce changement est crucial pour assurer que les fonctions de perte des modèles de classification s'exécutent correctement.
- **Filtrage des données très corrélées** : L'analyse a révélé que la colonne `fraud_type` était fortement corrélée à la colonne `fraud_flag`. Son exclusion a été décidée pour améliorer l'efficacité computationnelle.

2.3.2 Ingénierie des Caractéristiques (Feature Engineering)

Nous avons structuré nos variables en trois catégories :

1. **Indicateurs de solvabilité** : Le score CIBIL et le revenu mensuel (`monthly_income`) sont les pivots de la probabilité de remboursement.
2. **Variables de pression financière** : Le ratio `debt_to_income_ratio` capture la vulnérabilité économique, facteur lié aux comportements frauduleux.
3. **Traitement catégoriel** : Les variables textuelles (`loan_type`, `employment_status`) ont été transformées via un encodage **One-Hot**.

2.3.3 Concaténation et Structuration Finale

L'étape suivante est la fusion des blocs de données numériques et catégorielles par une **concaténation verticale**. Cette étape permet de reconstruire une matrice de caractéristiques X où chaque ligne représente une demande de prêt et chaque colonne une variable.

2.3.4 Échantillonnage et Division des Données

Compte tenu de la rareté des fraudes, nous avons utilisé un **découpage stratifié** (*Stratified Split*). Cette méthode assure que la proportion de classes minoritaires (anomalies) reste identique dans les ensembles d'entraînement et de test, permettant une évaluation fiable de la capacité du modèle à détecter des fraudes non rencontrées précédemment.

2.3.5 Méthodologie de modélisation

Pour notre détection d'anomalies, nous avons décidé d'utiliser un modèle d'Isolation Forest "standard" avec les hyperparamètres suggérés dans l'article étudié. Les problématiques de longueur du chemin visant à déterminer une anomalie étant déjà traitées par l'algorithme, nous avons donc travaillé avec le modèle initial suivant :

```
[ ] iforest_model = IsolationForest(
    n_estimators=100,      # t = 100 arbres (valeur par défaut de l'article)
    max_samples='auto',   # ψ = 256 (valeur par défaut 'auto' dans sklearn)
    contamination=0.1,     # Proportion attendue d'anomalies. Lorsqu'on fixe en 'auto' le modèle identifie +70% des données comme des outliers
    random_state=42,       # Pour la reproductibilité
    verbose=1              # Affiche une barre de progression
)
```

Figure 1: Modèle d'Isolation Forest initial

La suite de la méthodologie peut se résumer ainsi : après une première évaluation basée sur la variable `fraud_flag`, le modèle d'Isolation Forest est affiné par une optimisation d'hyperparamètres via `GridSearchCV`, `RandomSearchCV` et `Optuna`, en tenant compte du fort déséquilibre et du paradoxe de l'Accuracy grâce à un ensemble de métriques robustes au déséquilibre. En complément d'iForest, des modèles supervisés (**Random Forest** avec `class_weight`, **XGBoost** avec `scale_pos_weight`) sont introduits et combinés à des techniques de rééchantillonnage comme `SMOTE` et `SMOTEENN` pour mieux représenter la classe minoritaire. Un ajustement de seuil de décision est ensuite appliqué à ces modèles supervisés ainsi qu'à `iForest_Optuna` afin d'améliorer encore la détection, et d'autres détecteurs d'anomalies issus de l'article étudié, tels que `Local Outlier Factor` et `One-Class SVM`, sont également évalués ; l'ensemble des résultats est présenté et analysé dans la section suivante.

3 Analyse des résultats

3.1 Présentation quantitative et qualitative des résultats

3.1.1 Déséquilibre des données et paradoxe de l'Accuracy

Après analyse des données, nous constatons que seulement **2%** des observations ont un `fraud_flag = 1`, ce qui induit un fort déséquilibre impactant fortement la qualité de détection de l'Isolation Forest. Ce phénomène se traduit par une Accuracy apparemment élevée de 88.38% mais des Précision, Rappel et F1-Score très faibles (1.97%, 9.77% et 3.28%), ainsi qu'un AUC de 0.501, équivalent à un modèle aléatoire. Enfin, 90.23% des fraudes présentes dans les données d'entraînement ne sont pas détectées (faux négatifs), comme le confirment les courbes AUC-ROC et les matrices de confusion présentées en annexe.

Nous devons donc faire face au paradoxe de l'Accuracy. Pour y remédier, nous introduisons donc plusieurs métriques stables au déséquilibre des données telles que : l'AUPRC, la `Precision@k`, le `Recall@k`, les F1-score et F2-score, la Balanced Accuracy, le G-mean, le Matthews Correlation Coefficient, le Kappa de Cohen et l'indice de Jaccard. Les descriptions approfondies de chacune de ces métriques se trouvent en annexe.

Comme expliqué dans la section précédente, après application d'un Isolation Forest "standard", nous avons procédé à l'optimisation des hyperparamètres à l'aide des algorithmes de `GridSearchCV`, `Optuna` et `RandomSearchCV` et avons obtenus les résultats suivants pour les métriques citées plus haut :

	Model	AUPRC	ROC_AUC	F1	F2	Precision@k	Recall@k	Balanced_Acc	Gmean	MCC	Kappa	Jaccard
0	iForest_Optuna	0.020214	0.488757	0.035934	0.070168	0.011111	0.005495	0.498191	0.393230	-0.001282	-0.000687	0.018296
1	iForest_GridSearch	0.019839	0.480347	0.007168	0.006061	0.011111	0.005495	0.497314	0.073721	-0.007322	-0.006964	0.003597
2	iForest_RandomSearch	0.022900	0.487571	0.040252	0.059657	0.011111	0.005495	0.510170	0.286307	0.011364	0.009418	0.020539

Figure 2: Performances des différentes versions d'iForest avec hyperparamètres optimisés

Optuna fournit les meilleurs résultats parmi les trois méthodes d'optimisation, comme le montrent clairement

les graphiques complémentaires. Toutefois, les performances d'iForest en apprentissage non supervisé restent modestes et laissent une marge d'amélioration via d'autres approches.

3.1.2 Tentative d'amélioration avec d'autres modèles et gestion du déséquilibre

Dans l'optique d'améliorer les résultats, nous avons, comme décrit dans la section précédente, rajouté des modèles d'apprentissage supervisé, de rééchantillonnage préférentiel et des détecteurs d'anomalies de l'article étudié. Les résultats sont compilés dans le tableau ci-dessous :

	Model	AUPRC	ROC_AUC	F1	F2	Precision@k	Recall@k	Balanced_Acc	Gmean	MCC	Kappa	Jaccard
0	iForest_Optuna	0.020214	0.488757	0.035934	0.070168	0.011111	0.005495	0.498191	0.393230	-0.001282	-0.000687	0.018296
1	iForest_Optuna_thresh	0.020214	0.488757	0.037513	0.072554	0.011111	0.005495	0.502832	0.395493	0.002044	0.001123	0.019115
2	RF_class_weight	0.066400	0.649181	0.000000	0.000000	0.133333	0.065934	0.500000	0.000000	0.000000	0.000000	0.000000
3	RF_SMOTE	0.033653	0.605213	0.026882	0.027233	0.022222	0.010989	0.503267	0.164004	0.006397	0.006395	0.013624
4	XGB_SMOTEENN	0.025215	0.548719	0.034146	0.036611	0.022222	0.010989	0.506724	0.193648	0.012046	0.011966	0.017370
5	LOF	0.021077	0.482550	0.029963	0.024600	0.044444	0.021978	0.506405	0.147569	0.018642	0.017334	0.015209
6	OneClass_SVM	0.021376	0.497983	0.000000	0.000000	0.022222	0.010989	0.498359	0.000000	-0.008153	-0.005579	0.000000
7	XGB_SMOTEENN_thresh	0.025215	0.548719	0.046615	0.089438	0.022222	0.010989	0.526081	0.435376	0.019107	0.010713	0.023864

Figure 3: Comparatif final entre tous les candidats

3.2 Interprétation des résultats

Les résultats mettent d'abord en évidence les limites des approches purement non supervisées pour ce problème de fraude fortement déséquilibré. Les différentes variantes d'Isolation Forest optimisées (**iForest_Optuna**, **iForest_GridSearch**, **iForest_RandomSearch**) affichent des valeurs d'AUPRC autour de 0.02 et des F1/F2-scores très faibles, tandis que la **Balanced_Acc**, le **G-mean**, le **MCC**, le **Kappa** et l'indice de **Jaccard** restent proches de leurs valeurs neutres. Cela confirme que, même avec des hyperparamètres soigneusement ajustés, iForest reste peu discriminant : les fraudes ne sont pas suffisamment éloignées du nuage de transactions normales pour être détectées efficacement comme de simples anomalies (swamping) .

L'introduction de modèles supervisés et de techniques explicites de gestion du déséquilibre améliore nos résultats précédents. La forêt aléatoire avec pondération de classes (**RF_class_weight**) obtient la meilleure AUPRC (0.066) et une ROC_AUC d'environ 0.65, traduisant une meilleure capacité à ordonner les transactions par risque de fraude que les versions rééchantillonnées (**RF_SMOTE**, **XGB_SMOTEENN**) et, a fortiori, que les modèles non supervisés. Toutefois, les F1 et F2-scores restent globalement faibles pour tous les candidats, ce qui montre qu'il demeure difficile d'obtenir à la fois un rappel élevé et une précision satisfaisante au seuil par défaut. Les métriques **Precision@k** et **Recall@k** indiquent par ailleurs que, dans un scénario opérationnel où seules les k transactions les plus suspectes sont investiguées, **RF_class_weight** fournit la meilleure liste en termes de proportion de vraies fraudes, même si la couverture globale des fraudes reste limitée.

Enfin, les indicateurs globaux (**Balanced_Acc**, **G-mean**, **MCC**, **Kappa**, **Jaccard**) montrent que la majorité du gain provient d'un traitement correct de la classe majoritaire, avec un bénéfice réel mais modéré sur la classe frauduleuse.

Comme observé dans le tableau précédent, le modèle combinant **XGBoost**, **SMOTEENN** et un **ajustement du seuil** donne de meilleurs résultats qu'**iForest_Optuna**, avec une meilleure détection de fraudes et un écart réduit entre prédictions et valeurs réelles de **fraud_flag**. Avec **iForest_Optuna**, 20.83% des lignes de test diffèrent pour 80.77% de fraudes manquées, contre 19.05% de lignes différentes et 76.92% de fraudes manquées pour **XGBoost + SMOTEENN + ajustement de seuil**, qui devient ainsi notre candidat final du côté des méthodes supervisées, en amélioration les performances, du meilleur modèle non supervisé.

4 Conclusion et perspectives

Ce projet avait pour objectif d'étudier l'applicabilité de l'algorithme **Isolation Forest** à un problème actuariel réel de **détection de fraude** dans des demandes de prêts bancaires. Bien que cette méthode soit reconnue pour son efficacité dans de nombreux contextes de détection d'anomalies (Liu, F. T., et al., 2012), les résultats obtenus sur la base de données étudiée mettent en évidence plusieurs **limites structurelles** qui restreignent sa performance dans ce cas précis.

Une première limite majeure réside dans la **nature conditionnelle de la fraude**. Les analyses exploratoires, les mesures d'information mutuelle ainsi que les modèles statistiques et supervisés montrent l'absence de **dépendance marginale forte** entre la variable de fraude et les variables quantitatives prises isolément (montant du prêt, revenu, score de crédit, âge, etc.). La fraude ne se manifeste pas par des valeurs extrêmes facilement isolables, mais par des **incohérences contextuelles**, dépendant de **combinaisons de variables** et de leur adéquation à une situation donnée. Ce type de configuration correspond à la notion d'**anomalies conditionnelles** décrite par Song et al. (2007), que l'Isolation Forest ne cherche pas à modéliser explicitement, comme l'indiquent les auteurs dans leur formulation originale.

L'analyse met également en évidence le rôle structurant de la variable qualitative **non ordinale** *purpose_of_loan*. Bien que cette variable ne soit pas significative individuellement dans un cadre marginal, son introduction révèle une **dépendance conditionnelle globale** : certaines variables quantitatives deviennent informatives uniquement dans des contextes spécifiques définis par le type de prêt (voir annexe). Ce résultat est cohérent avec la logique métier du domaine bancaire, où la fraude dépend fortement de la **cohérence entre le profil du demandeur et l'objectif du prêt**. Or, comme souligné par Liu, F. T., et al., 2012, les méthodes basées sur l'isolation traitent imparfaitement les variables catégorielles, en raison de l'absence d'ordre naturel et du nombre limité de modalités, ce qui réduit leur impact dans le processus de partitionnement et peut dégrader les performances lorsque ces variables sont pertinentes.

Une autre difficulté importante tient au **fort déséquilibre des classes**, la fraude ne représentant qu'environ **2 %** des observations. Dans ce contexte, les méthodes de détection d'anomalies sont particulièrement sensibles à l'**effet de swamping**, dans lequel des observations normales sont faussement identifiées comme anomalies, tandis que les véritables fraudes restent noyées dans la masse des données normales (Wu et al., 2024). Ce phénomène contribue à expliquer les performances limitées observées, y compris lors de l'utilisation de modèles supervisés classiques, et renforce la difficulté de détecter des anomalies rares et contextuelles.

Ces différents éléments montrent que les performances limitées de l'Isolation Forest ne traduisent pas un échec méthodologique, mais reflètent au contraire les **hypothèses structurelles** de l'algorithme, qui ne sont pas pleinement vérifiées dans le contexte étudié. Ce travail met ainsi en évidence l'importance d'une **analyse critique** des méthodes employées et de leurs hypothèses sous-jacentes, en particulier dans des problématiques financières complexes.

De plus, plusieurs pistes pourraient être explorées afin de mieux traiter ce type de données. Des modèles intégrant explicitement les **interactions et dépendances conditionnelles**, tels que des modèles probabilistes ou des approches supervisées enrichies, pourraient être plus adaptés (Song et al., 2007). Par ailleurs, des travaux récents proposent des méthodes de détection d'anomalies conçues pour des classes fortement déséquilibrées, notamment via des techniques de **sur-échantillonnage** combinées à des algorithmes de détection d'anomalies (Rajaan et al., 2024 ; Zheng et al., 2019), ou via des cadres prenant en compte les **groupes rares et les enjeux d'équité** (Wu et al., 2024). Enfin, le développement de méthodes capables de mieux intégrer les **données mixtes**, combinant variables continues et qualitatives, constitue une direction naturelle pour prolonger cette étude.

5 Annexe

Matrices de confusion




Figure 4




Figure 5




Figure 6




Figure 7




Figure 8




Figure 9




Figure 10




Figure 11




Figure 12

Courbes ROC




Figure 13




Figure 14




Figure 15




Figure 16




Figure 17




Figure 18




Figure 19




Figure 20




Figure 21

Courbes Precision-Recall




Figure 22




Figure 23




Figure 24




Figure 25




Figure 26





Figure 27

Métriques d'évaluation

Métrique	Description
AUPRC	Aire sous la courbe précision-rappel, mesure la capacité globale à bien classer les fraudes malgré le fort déséquilibre.
Precision@k	Proportion de vraies fraudes dans le top k cas les plus suspects.
Recall@k	Proportion de toutes les fraudes réellement capturées dans ce top k .
F1-score	Compromis entre précision et rappel, avec poids égal.
F2-score	Version du F1-score qui donne plus d'importance au rappel.
Balanced Accuracy	Version de l'Accuracy tenant compte du déséquilibre des données.
G-mean	Racine du produit sensibilité $\times$ spécificité, mesure l'équilibre entre détection des fraudes et des normaux.
MCC	Matthews Correlation Coefficient , corrélation globale entre prédictions et vraies étiquettes, robuste au déséquilibre.
Kappa de Cohen	Accord modèle-vérité au-delà du hasard.
Indice de Jaccard	Similarité entre l'ensemble des fraudes prédites et réelles.

Table 1: Résumé des métriques utilisées pour l'évaluation des modèles de détection de fraude


Comparaison des performances iForest (Optuna / Grid / Random)




Métriques robustes au déséquilibre (MCC, Kappa, Jaccard)



Comparaison des performances (iForest / RF / XGB / LOF / OCSVM)





Autres analyses (partie 4)




Figure 28: La répartition de la variable fraud_flag met en évidence un fort déséquilibre des classes, la fraude ne représentant qu'une faible proportion des observations, ce qui complique la détection d'anomalies et favorise l'effet de **swamping**




Figure 29: pairplot(fraud vs variables quantitatives) : Absence de séparations marginales

	variable	MI
1	monthly_income	0.018243
3	loan_tenure_months	0.001174
0	loan_amount_requested	0.000983
4	applicant_age	0.000914
5	cibil_score	0.000650
2	debt_to_income_ratio	0.000219

Figure 30: Tableaux MI (Mutual Information) : aucune variable isolée n'est informative de la fraude

Generalized Linear Model Regression Results						
=====						
Dep. Variable:	fraud_flag	No. Observations:	50000			
Model:	GLM	Df Residuals:	49987			
Model Family:	Binomial	Df Model:	12			
Link Function:	Logit	Scale:	1.0000			
Method:	IRLS	Log-Likelihood:	-4992.2			
Date:	Thu, 08 Jan 2026	Deviance:	9984.4			
Time:	10:11:38	Pearson chi2:	5.00e+04			
No. Iterations:	7	Pseudo R-squ. (CS):	0.0004239			
Covariance Type:	nonrobust					
=====						
	coef	std err	z	P> z	[0.025	0.975]
-----	-----	-----	-----	-----	-----	-----
const	-4.0371	0.477	-8.462	0.000	-4.972	-3.102
loan_amount_requested	-1.494e-07	1.16e-07	-1.293	0.196	-3.76e-07	7.71e-08
loan_tenure_months	-1.639e-05	0.000	-0.063	0.950	-0.001	0.000
monthly_income	4.989e-07	1.6e-06	0.311	0.756	-2.64e-06	3.64e-06
cibil_score	0.0001	0.001	0.226	0.821	-0.001	0.001
applicant_age	0.0026	0.002	1.065	0.287	-0.002	0.007
debt_to_income_ratio	0.0047	0.004	1.228	0.219	-0.003	0.012
purpose_Debt Consolidation	-0.0223	0.117	-0.191	0.849	-0.251	0.207
purpose_Education	-0.1850	0.122	-1.515	0.130	-0.424	0.054
purpose_Home Renovation	0.2124	0.111	1.920	0.055	-0.004	0.429
purpose_Medical Emergency	-0.1075	0.119	-0.900	0.368	-0.342	0.127
purpose_Vehicle Purchase	-0.1639	0.122	-1.345	0.179	-0.403	0.075
purpose_Wedding	0.0029	0.116	0.025	0.980	-0.225	0.230

Figure 31: Régression logistique avec variable contextuelle "purpose_of_loan" : L'ajout de "purpose_of_loan" révèle une dépendance conditionnelle globale, bien que les modalités ne soient pas significatives individuellement.

LR statistic (purpose): 16.51283900180897
p-value (purpose): 0.01125066001096154

Figure 32: Test du rapport de vraisemblance – Effet global de "purpose_of_loan" : Le test du rapport de vraisemblance confirme une amélioration significative du modèle lorsque le contexte du prêt est pris en compte.



Figure 33: Les écarts de taux de fraude entre types de prêts soulignent l'importance du contexte transactionnel et renforcent l'existence de dépendances conditionnelles.